

Как использовать sed/grep для извлечения текста между двумя словами?

Задан вопрос 13 лет и 10 месяцев назад · Изменено 3 года и 2 месяца назад · Просмотрено 763 тыс. раз



228



Я пытаюсь вывести строку, содержащую всё, что находится между двумя словами другой строки:

ВХОД:

```
"Here is a String"
```

ВЫХОД:

```
"is a"
```

С использованием:

```
sed -n '/Here/,/String/p'
```

Включает конечные точки, но я не хочу их включать.

нить баш сед grep

Копия

Копия

Копия

Делиться Улучшите этот вопрос
Следовать

Отредактировано 25 мая 2017 г.
в 4:39



анишане

21,2 тыс. 5 48 78

Вопрос задан 6 ноября 2012 г. в
0:08.



пользователь1190650

3445 6 30 34

- 11 Какой должен быть результат, если на вход подается Here is a Here String ? Или I Hereby Dub Thee Sir Stringy ? – [гхоти](#) 6 ноября 2012 г., 0:17
- 6 К вашему сведению. Ваша команда должна вывести всё, что находится между строкой со словом Here и строкой со словом String – это не то, что вам нужно. – [Хай](#) [Бу](#) 6 ноября 2012 г., 0:54
- 1 Ещё один часто sed задаваемый вопрос – «как извлечь текст между определёнными строками»; вот ссылка на него: stackoverflow.com/questions/16643288/... – [триплее](#) 30 июля 2020 г., 5:44

14 ответов

Отсортировано по:

Наивысший балл (по умолчанию)



262



Команда `GNU grep` также поддерживает положительный и отрицательный просмотр вперед и назад: в вашем случае команда будет выглядеть так:

Копия

```
echo "Here is a string" | grep -o -P '(?<=Here).*(?=string)'
```

Если символы встречаются несколько раз `string`, вы можете выбрать, хотите ли вы сопоставлять первый `Here` и последний символы `string` или сопоставлять их по отдельности. В контексте регулярных выражений это называется жадным сопоставлением (первый случай) или нежадным сопоставлением (второй случай).

Копия

```
$ echo 'Here is a string, and Here is another string.' | grep -oP '(?<=Here).*(?=string)' # Greedy match
is a string, and Here is another
$ echo 'Here is a string, and Here is another string.' | grep -oP '(?<=Here).*?(?=string)' # Non-greedy match (Notice the '?' after '*' in .*)
is a
is another
```

Делиться Улучшите этот ответ
Следовать

Отредактировано 21 февраля 2019
г. в 4:03

Ответ дан 6 ноября 2012 г. в
6:58.



анишане

21,2 тыс. 5 48 78

25 комментариев ^

Добавить комментарий



gхоти Более года назад

Обратите внимание, что опция `grep` в GNU grep -P отсутствует в версиях, grep входящих в состав *BSD, а также в версиях, поставляемых с SVR4 (Solaris и т. д.). В FreeBSD можно установить devel/pcre порт, который включает в себя `grep` pcregrep, поддерживающий PCRE (и опережающий/запаздывающий просмотр). Более старые версии OSX использовали GNU grep, но в OSX Mavericks `grep` -P основан на версии из FreeBSD, которая не включает эту опцию.

44

Отвечать



Дургеш Сутхар Более года назад

Здравствуйте, как мне извлечь только уникальное содержимое?

1

Отвечать



Батл Буткус Более года назад

Это не сработает, потому что если ваша завершающая строка "string" встречается более одного раза, будет получено *последнее* вхождение, а не *следующее*.

4

Отвечать





анишане Более года назад

В случае с `Here is a string a string`, оба `" is a "` варианта `" is a string a "` являются допустимыми ответами (кавычки игнорируйте), согласно требованиям вопроса. Выбор за вами, какой из них **вам** больше подходит, и ответ может отличаться. В любом случае, для ваших целей подойдет следующий вариант: `echo "Here is a string a string" | grep -o -P '(?<=Here).*(?=string)'`

▲ 7

Отвечать



анишане Более года назад

@BND, вам нужно включить [функцию многострочного поиска в pcregrep](#). `echo $'Here is \na string' | grep -zoP '(?<=Here)(?s).*(?=string)'`

▲ 4

Отвечать



159



Копия

```
sed -e 's/Here\(.*\)String/\1/'
```

Делиться Улучшите этот ответ Следовать

Ответ дан 6 ноября 2012 г. в 0:14.



Брайан Кэмпбелл

336 тыс. 59 369 344

10 комментариев ^

Добавить комментарий



пользователь1190650 Более года назад

Спасибо! А что, если я захочу найти всё, что находится между `"one is"` и `"String"` в `"Here is a one is a String"`? (`sed -e 's/one is(.*)String/\1/'` ?

▲ 2

Отвечать



Брайан Кэмпбелл Более года назад

@user1190650 Это сработает, если вы хотите увидеть и `"Here is a"`. Можете проверить: `echo "Here is a one is a String" | sed -e 's/one is\(.*\)String/\1/'`. Если вам нужна только часть между `"one is"` и `"String"`, то вам нужно сделать так, чтобы регулярное выражение соответствовало всей строке: `sed -e 's/.*one is\(.*\)String.*/\1/'`. В `sed` `s/pattern/replacement/` напишите "заменить 'pattern' на 'replacement' в каждой строке". Это изменит только то, что соответствует `"pattern"`, поэтому, если вы хотите заменить всю строку, вам нужно сделать так, чтобы `"pattern"` соответствовал всей строке.

▲ 10

Отвечать



Джей Ди Более года назад

Это приводит к ошибке при вводе данных. `Here is a String Here is a String`

▲ 9

Отвечать



Джей Ди Более года назад

Было бы здорово увидеть решение для случая: "Here is a blah blah String Here is 1 a blah blah String Here is 2 a blash blash String" – вывод должен отображать только первую подстроку между Here и String".

▲ 1 Отвечать ...



[Брайан Кэмпбелл](#) Более года назад

@JayD sed does not support non-greedy matching, see [this question](#) for some recommended alternatives.

▲ 1 Reply ...



The accepted answer does not remove text that could be before `Here` or after `String`. This will:

104



```
sed -e 's/.*Here\(.*\)String.*/\1/'
```

Copy



The main difference is the addition of `.*` immediately before `Here` and after `String`.

[Share](#) [Improve this answer](#) [Follow](#)

answered May 5, 2017 at 3:23



[wheeler](#)

3,391 4 33 50

9 Comments ^

Add a comment



[drmaa](#) Over a year ago

Your answer is promising. One issue though. How can I extract it to the first seen String if there are multiple String in the same line? Thanks

▲ 0 Reply ...



[wheeler](#) Over a year ago

@MianAsbatAhmad You would want to make the `*` quantifier, between `Here` and `String`, non-greedy (or lazy). However, the type of regex used by sed does not support lazy quantifiers (a `?` immediately after `.*`) according to [this Stackoverflow question](#). Usually to implement a lazy quantifier you would just match against everything except the token you didn't want to match, but in this case, there isn't just a single token, instead its a whole string, `String`.

▲ 0 Reply ...



[drmaa](#) Over a year ago

Thanks, I got the answer using awk, stackoverflow.com/questions/51041463/...

▲ 0 Reply ...



[WitaloBenicio](#) Over a year ago

Unfortunately this doesn't work if the string has line breaks

▲ 1 Reply ...



[wheeler](#) Over a year ago

It's not supposed to. `.` doesn't match line breaks. If you want to match line breaks, you can replace `.` with something like `[\s\s]`.

▲ 0 Reply ...



You can strip strings in [Bash](#) alone:

48

Copy



```
$ foo="Here is a String"
$ foo=${foo##*Here }
$ echo "$foo"
is a String
$ foo=${foo%% String*}
$ echo "$foo"
is a
$
```

And if you have a GNU grep that includes [PCRE](#), you can use a zero-width assertion:

Copy

```
$ echo "Here is a String" | grep -Po '(?<=(Here )).*(?:= String)'\n\nis a
```

Share Improve this answer

edited Oct 20, 2016 at 20:35

answered Nov 6, 2012 at 0:19

Follow



[ghoti](#)

47.3k 8 71 109

4 Comments ^

Add a comment



[Adam Johns](#) Over a year ago

why is this method so slow? when stripping a large html page using this method it takes like 10 seconds.

▲ 0 Reply ...



[ghoti](#) Over a year ago

@AdamJohns, which method? The PCRE one? PCRE is fairly complex to parse, but 10 seconds seems extreme. If you're concerned, I recommend you [pose a question](#) including example code, and see what the experts say.

▲ 0 Reply ...



[Adam Johns](#) Over a year ago

I think it was so slow for me because it was holding a very large html file's source in a variable. When I wrote contents to file and then parsed the file the speed dramatically increased.

▲ 1 Reply ...



[Akito](#) Over a year ago

Should be the accepted answer, because it uses pure Bash.

▲ 0 Reply ...



If you have a long file with many multi-line occurrences, it is useful to first print number lines:

37



```
cat -n file | sed -n '/Here/,/String/p'
```



Share Improve this answer

edited Jun 5, 2015 at 9:18

answered Jun 8, 2013 at 13:11



Follow



Juve

10.9k

14

70

95



alemol

8,778

2

29

32

2 Comments ^

Add a comment



Jeffrey Lebowski Over a year ago

Thanks! This is the only solution which worked in my case (multiple line text file, rather than a single string with no line breaks). Obviously, to have it without line numbering, the `-n` option in `cat` must be omitted.



6



Reply



tripleee Over a year ago

... in which case `cat` can be entirely omitted; `sed` knows how to read a file or standard input.



2



Reply



Through GNU awk,

31



```
$ echo "Here is a string" | awk -v FS="(Here|string)" '{print $2}'
is a
```



`grep` with `-P` (*perl-regexp*) parameter supports `\k`, which helps in discarding the previously matched characters. In our case, the previously matched string was `Here` so it got discarded from the final output.



```
$ echo "Here is a string" | grep -oP 'Here\K.*(?:=string)'
is a
$ echo "Here is a string" | grep -oP 'Here\K(?:?!string).*)'
is a
```

If you want the output to be `is a` then you could try the below,



```
$ echo "Here is a string" | grep -oP 'Here\s*\K.*(?:=\s+string)'
is a
```

```
$ echo "Here is a string" | grep -oP 'Here\s*\K(?:?!s+string).)*'
is a
```

Share Improve this answer

edited Aug 19, 2014 at 15:19

answered Aug 19, 2014 at 15:07

Follow



Avinash Raj

175k 32 250 293

1 Comment ^

Add a comment



alper Over a year ago

This does not work for: `echo "Here is a string dfdsf Here is a string" | awk -v FS="(Here|string)" '{print $2}'`, it only returns `is a` instead of should be `is a is a` @Avinash Raj

▲ 0

Reply



You can use two s commands

12

Copy



```
$ echo "Here is a String" | sed 's/.*Here//; s/String.*//'
is a
```



Also works



Copy

```
$ echo "Here is a StringHere is a String" | sed 's/.*Here//; s/String.*//'
is a
```

```
$ echo "Here is a StringHere is a StringHere is a StringHere is a String" | sed
's/.*Here//; s/String.*//'
is a
```

Share Improve this answer Follow

answered Feb 5, 2020 at 9:56



Ivan

7,588 1 23 27

Comments

Add a comment

To understand `sed` command, we have to build it step by step.

12

Here is your original text



Copy



```
user@linux:~$ echo "Here is a String"
Here is a String
user@linux:~$
```

Let's try to remove `Here` string with `s` ubstition option in `sed`



```
user@linux:~$ echo "Here is a String" | sed 's/Here //'
is a String
user@linux:~$
```

At this point, I believe you would be able to remove `String` as well



```
user@linux:~$ echo "Here is a String" | sed 's/String//'
Here is a
user@linux:~$
```

But this is not your desired output.

To combine two `sed` commands, use `-e` option



```
user@linux:~$ echo "Here is a String" | sed -e 's/Here //' -e 's/String//'
is a
user@linux:~$
```

Hope this helps

Share Improve this answer

edited Jul 3, 2020 at 14:44

answered Oct 11, 2018 at 4:17

Follow

user9013730

1 Comment ^

Add a comment



Kosz Over a year ago

Thank you for this - the explanation on what exactly it's doing was very helpful for me to understand



0



Reply



This might work for you (GNU sed):

9



```
sed '/Here/!d;s///&\n/;s/.*\n//;a;/String/bb;${n;ba};;b;s///&\n/;P;D' file
```





This presents each representation of text between two markers (in this instance Here and String) on a newline and preserves newlines within the text.



Share Improve this answer

edited Nov 6, 2012 at 0:50

answered Nov 6, 2012 at 0:42

Follow



potong

59.6k

6

55

93

Comments

Add a comment



All the above solutions have deficiencies where the last search string is repeated elsewhere in the string. I found it best to write a bash function.

8



Copy



```
function str_str {
    local str
    str="${1#*${2}}"
    str="${str%%$3*}"
    echo -n "$str"
}

# test it ...
mystr="this is a string"
str_str "$mystr" "this " " string"
```

Share Improve this answer

edited Jun 17, 2015 at 6:19

answered Jun 17, 2015 at 4:45

Follow



Gary Dean

115

1

6

Comments

Add a comment



You can use \1 (refer to <http://www.grymoire.com/Unix/Sed.html#uh-4>):

4

Copy



```
echo "Hello is a String" | sed 's/Hello\(.*\)String/\1/g'
```



The contents that is inside the brackets will be stored as \1 .



Share Improve this answer

edited Aug 19, 2014 at 21:14

Ответ дан 6 ноября 2012 г. в 0:19.

Follow



Питер Мортенсен

30,8 тыс.

22

112

135



мвайраван

129

1

11

1 комментарий ^

Добавить комментарий



Джонатан Более года назад ✎

Это удаляет строки вместо вывода чего-то промежуточного. Попробуйте удалить "Hello" с помощью "is" в команде sed, и она выведет "Hello a".



Отвечать



1



Проблема. Сохраненные сообщения Claws Mail имеют следующий формат, и я пытаюсь извлечь из них заголовки:

Копия

```
Subject: [SLC38A9 lysosomal arginine sensor; mTORC1 pathway] Key molecular
link in major cell growth pathway: Findings point to new potential
therapeutic target in pancreatic cancer [mTORC1 Activator SLC38A9 Is
Required to Efflux Essential Amino Acids from Lysosomes and Use Protein as
a Nutrient] [Re: Nutrient sensor in key growth-regulating metabolic pathway
identified [Lysosomal amino acid transporter SLC38A9 signals arginine
sufficiency to mTORC1]]
Message-ID: <20171019190902.18741771@VictoriasJourney.com>
```

Как указано в пункте A2 этой темы, [как использовать sed/grep для извлечения текста между двумя словами?](#) Первое выражение, приведенное ниже, «работает», если найденный текст не содержит символа новой строки:

Копия

```
grep -o -P '(?<=Subject: ).*(?=molecular)' corpus/01

[SLC38A9 lysosomal arginine sensor; mTORC1 pathway] Key
```

Однако, несмотря на многочисленные попытки `.+?; /s; ...`, мне не удалось заставить их работать:

Копия

```
grep -o -P '(?<=Subject: ).*(?=link)' corpus/01
grep -o -P '(?<=Subject: ).*(?=therapeutic)' corpus/01
etc.
```

Решение 1.

Для [извлечения текста между двумя строками на разных строках](#)

Копия

```
sed -n '/Subject: /{:a;N;/Message-ID:!/ba; s/\n/ /g; s/\s\s*/ /g; s/.*Subject:
\|Message-ID:.*//g;p}' corpus/01
```

что дает



[SLC38A9 lysosomal arginine sensor; mTORC1 pathway] Key molecular [link](#) in major cell growth pathway: Findings point to new potential therapeutic target [in](#) pancreatic cancer [mTORC1 Activator SLC38A9 Is Required to Efflux Essential Amino Acids from Lysosomes and Use Protein as a Nutrient] [Re: Nutrient sensor [in](#) key growth-regulating metabolic pathway identified [Lysosomal amino acid transporter SLC38A9 signals arginine sufficiency to mTORC1]]

Решение 2.*

Как [заменить символ новой строки \(\n\) с помощью команды sed?](#)



```
sed ':a;N;$!ba;s/\n/ /g' corpus/01
```

Заменит символы новой строки пробелом.

Соединив это с пунктом A2 в статье [«Как использовать sed/grep для извлечения текста между двумя словами?»](#), мы получаем:



```
sed ':a;N;$!ba;s/\n/ /g' corpus/01 | grep -o -P '(?<=Subject: ).*(?=Message-ID: )'
```

что дает



[SLC38A9 lysosomal arginine sensor; mTORC1 pathway] Key molecular [link](#) in major cell growth pathway: Findings point to new potential therapeutic target [in](#) pancreatic cancer [mTORC1 Activator SLC38A9 Is Required to Efflux Essential Amino Acids from Lysosomes and Use Protein as a Nutrient] [Re: Nutrient sensor [in](#) key growth-regulating metabolic pathway identified [Lysosomal amino acid transporter SLC38A9 signals arginine sufficiency to mTORC1]]

Этот вариант удаляет двойные пробелы:



```
sed ':a;N;$!ba;s/\n/ /g; s/\s\s*/ /g' corpus/01 | grep -o -P '(?<=Subject: ).*(?=Message-ID: )'
```

дарение



[SLC38A9 lysosomal arginine sensor; mTORC1 pathway] Key molecular [link](#) in major cell growth pathway: Findings point to new potential therapeutic target [in](#) pancreatic cancer [mTORC1 Activator SLC38A9 Is Required to Efflux Essential Amino Acids from Lysosomes and Use Protein as a Nutrient] [Re: Nutrient sensor [in](#) key growth-regulating metabolic pathway identified [Lysosomal amino acid transporter SLC38A9 signals arginine sufficiency to mTORC1]]

[Делиться](#) [Улучшите этот ответ](#) [Следовать](#)

Ответ дан 1 декабря 2017 г. в 22:51.

**Виктория Стюарт**

5,210 2 49 44

1 комментарий ^

**Алекс ММ** Более года назад

Замечательное приключение :))

 [rippgrep](#)

1

Вот пример с использованием [rg](#) :

Копия

```
$ echo Here is a String | rg 'Here\s(.*)\sString' -r '$1'
is a
```

[Делиться](#) [Улучшите этот ответ](#) [Следовать](#)

Ответ дан 20 апреля 2022 г. в 13:14.

**кенорб**

169 тыс. 97 716 803

Комментарии



0

Вот моё не слишком изящное, но работающее решение:

Копия

```
$ echo 'Here is a String' | sed 's/Here/\n/g' | sed 's/String/\n/g' | sed -r
'/^[[[:space:]]*$/d'
```

is a



но работает Here is a String Here is a second String и с:

Копия

```
$ echo 'Here is a String Here is a second String' | sed 's/Here/\n/g' | sed
's/String/\n/g' | sed -r '/^[[[:space:]]*$/d'
```

is a

is a second

или:



```
$ echo 'Here is a String Here is a second String Here is last String' | sed  
's/Here/\n/g' | sed 's/String/\n/g' | sed -r '/^[:space:]]*$/d'
```

```
is a  
is a second  
is last
```

Делиться Улучшите этот ответ Следовать

Ответ дан 11 августа 2022 г. в 7:10.



Иван

114 2 4

Комментарии

Добавить комментарий

Начните задавать вопросы, чтобы получить ответы.

Найдите ответ на свой вопрос, задав его.

Задайте вопрос

Изучите связанные вопросы.

нить баш сед грег

Посмотрите похожие вопросы с этими тегами.